

Bull Protector Hacker AI (BPHAI)

Protocollo Totem e l'Intelligenza Senza Prompt

Dr.Francesco Bulla

Giugno 2025

«Perché ritengo che non è giusto che chi crea, lavora o fonda un'azienda venga derubato o dimenticato.» Francesco.B

Sommario

BPHAI propone un nuovo paradigma di sicurezza per l'IA che elimina i prompt testuali, trasformando la principale superficie di attacco in un vantaggio difensivo. I prompt diventano *comportamenti radicati* dentro Unità Neurali Radicate (UNR), che cooperano attraverso canali mascherati quali binario, stringa oppure token. Il risultato è un'intelligenza polimorfa, decentralizzata e intrinsecamente resistente al prompt-injection.

1 Introduzione

I modelli di linguaggio di grandi dimensioni quali definiti appunto (Large Language Models, LLM) non solo rivoluzionano le applicazioni digitali ma restano vulnerabili agli attacchi di *prompt injection*. Studi e linee guida di sicurezza quali ([OWASP GenAI 2025](#)) indicano il prompt injection non solo come una minaccia non solo in quei sistemi basati sugli LLM, ma anche e soprattutto tutti quei sistemi che li circondano quali Agenti, piattaforme, assistenti e.g. Codesti Approcci cquali i RAG, i filtri e perfino il fine-tuning non garantiscono affatto una protezione completa. Per tale contesto che nasce **Bull Protector Hacker AI (BPHAI)**: una **rete di Unità Neurali Radicate (UNR)** in cui i prompt non esistono come stringhe visibili bensì sono *incorporati nei pesi delle singole UNR*. L'assenza di prompt testuali rimuove di fatto la superficie di attacco.

2 Prompt radicato vs. prompt testuale

Nei LLM tradizionali il prompt è una stringa d'input manipolabile. In BPHAI invece una UNR contiene un *prompt radicato*: un set di policy apprese e sigillate nel grafo sinaptico. L'input del utente è trattato come *dato da processare*, non come nuova istruzione. Non esistendo stringhe di controllo esposte, il tentativo di injection fallisce a priori.

3 Architettura generale

1. **Input mascherato**: arriva come pacchetto binario/JSON cifrato (es. "1010107").
2. **Catena di UNR** $\{G_1, G_2, \dots\}$: ogni UNR applica il proprio comportamento radicato e trasforma l'informazione senza conoscere la logica globale.
3. **Modello LLM codificatore**: orchestra le UNR, aggrega i loro output, effettua masking e produce la risposta simulata.
4. **Mascheramento dinamico**: un modulo di *Move Masking* genera risposte plausibili a richieste sospette.




Figura 1: Enter Caption

5. **Decodifica controllata:** l'output reale è sbloccato solo se le policy interne lo permettono.

4 Comunicazione a tre canali

Le UNR comunicano su tre piani simultanei:

Canale 1 (010101) segnalazione binaria a bassa latenza per controllo, heartbeat, quorum.

Canale 2 (Stringhe) messaggi naturali compressi e firmati, usati solo per negoziazioni complesse.

Canale 3 (Token) embedding semantici che attraversano le UNR; qui avviene la vera trasformazione cognitiva.

Ogni canale è cifrato, routato su path casuali e può essere *falsificato* per confondere eventuali attaccanti.

5 Varianti MASKAI, TOTEM, RNM

- **TOTEM** – baseline: orchestrazione sinaptica, mascheramento leggero.
- **MASKAI** – strati extra di offuscamento e chiavi locali per ciascuna UNR.
- **RNM** – rete con proxy crittografati, proof di integrità (TLSNotary) e pagamenti anonimi.

6 Validazione tecnica delle Unità Neurali Radicate

La ricerca attuale che ho svolto non solo dimostra che i fondamenti tecnici delle UNR sono scientificamente solidi. Le architetture neurali distribuite come DISTANA hanno già dimostrato

la fattibilità di unità di elaborazione locali interconnesse, mentre le tecniche di weight embedding nei layer di embedding mostrano che i pesi neurali possono effettivamente memorizzare informazioni semantiche complesse.

Il concetto di "**prompt radicato**" trova supporto nelle tecniche esistenti di **neural compilation e hypernetwork**, dove reti neurali generano pesi di altre reti da descrizioni testuali. L'innovazione chiave di BPHAI sta nell'applicare questi principi specificamente alla sicurezza, incorporando vincoli comportamentali direttamente nei pesi piuttosto che fare affidamento su validazione esterna.

Le tecniche di neural obfuscation e crittografia neurale forniscono precedenti per l'integrazione di proprietà di sicurezza nell'architettura neurale. La ricerca su **Tree Parity Machines e neural watermarking** dimostra che è possibile incorporare proprietà crittografiche nei pesi neurali mantenendo la funzionalità del modello.

7 Confronto con lo stato dell'arte nella sicurezza AI

L'analisi del panorama attuale della sicurezza AI rivela non solo limitazioni fondamentali negli approcci tradizionali che BPHAI potrebbe superare. I sistemi di difesa attuali quali - Constitutional AI, adversarial training, e input sanitization - ci dimostrano che i tassi di bypass del 60-80% contro attacchi sofisticati, con il **framework HouYi** che compromette 31 su 36 applicazioni LLM reali. Constitutional AI di Anthropic, considerato all'avanguardia, raggiunge solo il 15-25% di riduzione nella generazione di contenuti dannosi. Anche **SmoothLLM**, che ottiene non solo tassi di successo degli attacchi <1%, richiede overhead computazionale significativo attraverso multiple copie perturbate degli input.

BPHAI presenta **attualmente** solo vantaggi teorici significativi rispetto a questi approcci:

- **Resistenza intrinseca:** Molto più difficile da aggirare attraverso prompt avversariali
- **Robustezza al fine-tuning:** Meno vulnerabile agli attacchi di allineamento fragile
- **Overhead ridotto:** Potenzialmente minore sovraccarico computazionale
- **Sicurezza architettónica:** Proprietà di sicurezza integrate a livello di modello

8 Ristrutturazione per standard accademici

Per soddisfare tali criteri di pubblicazione delle principali conferenze AI, il paper BPHAI richiede ristrutturazione sostanziale secondo gli standard di venues come **NeurIPS**, **ICLR** e **ICML**.

8.1 Abstract e posizionamento

L'abstract deve seguire la struttura in 5 componenti qui integrati : prima di tutti il problem statement (vulnerabilità specifiche dei prompt injection), motivazione (per un'importanza crescente della sicurezza AI), approccio (UNR e weight embedding), risultati quantitativi (per delle metriche di performance concrete), e implicazioni (impatto sulla ricerca in sicurezza AI).

Il related work necessita di organizzazione per categorie tematiche - metodi di attacco, meccanismi di difesa, metodologie di valutazione - piuttosto che cronologica, con chiaro posizionamento rispetto agli approcci esistenti come Constitutional AI, adversarial training, e architectural defenses.

8.2 Metodologia e validazione sperimentale

La sezione metodologica deve includere formalizzazione matematica rigorosa delle UNR, specificazione del **threat model**, e analisi teorica delle proprietà di sicurezza. Cruciale è l'implementazione

adaptive attacks - non solo attacchi base - per dimostrare robustezza reale. La validazione sperimentale deve senza alcun irragionevole dubbio un confronto con baseline forti (Constitutional AI, SmoothLLM, circuit breakers) utilizzando benchmark standardizzati come PromptBench e HarmBench, con metriche specifiche per la sicurezza come Attack Success Rate, detection rate, e tempo di risposta.

9 Approfondimenti tecnici dell'architettura

L'architettura UNR necessita di specifica tecnica dettagliata per passare da concept a implementazione. Basandosi sulla ricerca su **distributed neural architectures**, ogni UNR dovrebbe implementare i seguenti punti:

9.1 Struttura interna

Prediction kernels (PK) per elaborazione locale, transition kernels (TK) per comunicazione inter-UNR, e meccanismi di consensus per sincronizzazione distribuita. I tre canali di comunicazione che sono (**MASKAI, TOTEM, RNM**) e richiedono protocolli di comunicazione specifici con garanzie crittografiche.

9.2 Weight embedding

> Adottare tecniche basate su hypernetwork per generare pesi derivanti da prompt comportamentali, assicurando la conservazione dell'informazione semantica tramite funzioni di loss specializzate. L'implementazione dovrebbe fare leva su framework esistenti, come quelli per la compilazione neurale, per garantire maggiore efficienza.

9.3 Sicurezza crittografica

Integrazione di neural cryptography techniques per proteggere i pesi embedded, utilizzando approcci come fragile watermarking per tamper detection e neural obfuscation per resistance ai reverse engineering attempts.

10 Benchmark e metodologie di validazione

Per validare l'efficacia di BPHAI sono necessari protocolli di testing rigorosi. I benchmark primari includono PromptBench (18 tipi di attacco su 63 task), HarmBench (400+ comportamenti dannosi), e JailbreakBench (100+ prompt di jailbreaking).

Le metriche target dovrebbero essere: Attack Success Rate <1%, Detection Rate >99.5%, False Positive Rate <2%, e Response Time <100ms per applicazioni real-time. L'overhead computazionale deve rimanere sotto il 15% rispetto ai modelli base.

Il testing deve includere red team evaluation con attack generation automatizzata, edge case identification, e continuous monitoring per pattern anomali. Implementare pipeline di valutazione automatizzata usando framework come DeepEval per testing sistematico.

11 Casi d'uso e applicazioni

BPHAI presenta applicabilità particolarmente promettente in settori high-stakes:

11.1 Servizi finanziari

Protezione di AI assistants per trading e advisory, dove prompt injection potrebbe causare perdite finanziarie significative. La natura intrinseca della sicurezza BPHAI riduce i rischi di manipolazione esterna.

11.2 Healthcare AI

Sistemi di diagnosi e raccomandazioni terapeutiche, dove la compromissione potrebbe avere conseguenze sulla salute. L'embedding dei vincoli etici e medici nei pesi neurali garantisce aderenza costante ai protocolli.

11.3 Autonomous systems

Veicoli autonomi e robotics, dove la sicurezza comportamentale deve essere garantita indipendentemente da input esterni maliziosi.

12 Criticità e limitazioni implementative

Ma come mi hanno insegnato non è tutto oro quello che luccica, quindi le sfide tecniche significative ci sono ed emergono quali:

12.1 Complessità implementativa

La sincronizzazione di UNR distribuite richiede protocolli di consensus robusti con gestione di network partitions e Byzantine failures. L'overhead di comunicazione inter-UNR potrebbe limitare la scalabilità.

12.2 Preservazione semantica

Garantire che l'embedding dei prompt nei pesi non degradi le performance del modello base richiede ottimizzazione sofisticata e tecniche di regularization avanzate.

12.3 Verifica formale

Dimostrare matematicamente le proprietà di sicurezza delle UNR rappresenta una sfida significativa, richiedendo framework di formal verification per neural networks.

12.4 Adaptive adversaries

Attaccanti sofisticati potrebbero sviluppare tecniche specifiche per compromettere sistemi weight-embedded, richiedendo continuous evolution delle difese.

Ma nella prima versione mi occuperò di creare e stabilizzare il modello per poi andarlo a migliorare.

13 Innovazioni correlate e protezione IP

Prima di concludere volevo affermare che la ricerca di brevetti e progetti correlati in tale ambito rivelano un landscape competitivo limitato, suggerendo opportunità significativa per protezione IP. Aziende come Lakera e Robust Intelligence offrono soluzioni complementari ma non competitive dirette.

Raccomandazione di filing provisional patent per l'architettura UNR core prima della pubblicazione, coprendo: weight embedding techniques per sicurezza, distributed neural consensus protocols, e prompt-to-weight transformation methods.

14 Vantaggi principali

1. **Prompt invisibile:** nessuna stringa attaccabile.
2. **Mascheramento dinamico:** l'attaccante vede solo risposte placebo.
3. **Scalabilità modulare:** aggiungi nuove UNR senza toccare il core.
4. **Privacy by design:** dati sensibili restano all'interno delle UNR.

15 Conclusioni e prossimi passi

BPHAI penso che rappresenti non solo un'innovazione paradigmatica con potenziale trasformativo per la sicurezza AI. L'approccio di embedding comportamentale nei pesi neurali potrebbe superare limitazioni fondamentali degli approcci attuali, offrendo sicurezza intrinseca piuttosto che esterna.

Il percorso verso implementazione richiede ristrutturazione accademica rigorosa, validazione sperimentale estensiva, e development incrementale attraverso proof of concept. Con execution appropriata, BPHAI potrebbe stabilire nuovo standard per architectural AI security, contribuendo significativamente sia alla ricerca che all'applicazione pratica della sicurezza AI.

La combinazione di solidità teorica, innovazione tecnica, e applicabilità pratica posiziona BPHAI come contributo potenzialmente high-impact nel campo della AI safety e security architecture.

BPHAI inaugura l'era dell'*Intelligenza senza Prompt*, convertendo il principale tallone d'Achille degli LLM in un punto di forza. Il prossimo passo è rilasciare un prototipo open-source (licenza BullAI-Promptless) e avviare la peer review accademica.

Autore: Francesco Bulla – 150francescobulla@gmail.com

© BullAI-Promptless License v1 (CC-BY-NC compatibile) © 2025 [Dr.Francesco bulla catania - 05-06-2025]